《最优化算法与理论》实验报告

实验序号:	4
实验内容:	无约束优化算法程序优化
班　　级:	信息 2301
学　　号:	202310040128
姓　　名:	雷龙浩
完成日期:	2026 年 04 月 12 日

目录

1 问题背景与算法原理 **3**

1.1 扩展 Rosenbrock 问题 3

1.2 梯度、Hessian 及其结构 3

1.3 为什么选 FR 做对比 3

1.4 FR 共轭梯度法简述 4

1.5 非精确牛顿法与内层共轭梯度 4

1.6 为什么要 Hessian-向量积 5

2 程序实现说明 **5**

2.1 实验流程 5

2.2 实现要点 5

2.3 实验参数 6

3 实验结果与分析 **6**

3.1 程序优化前后时间对比 6

3.2 FR 与 Newton-CG 的比较 7

1 问题背景与算法原理

1.1 扩展 Rosenbrock 问题

本次实验考虑的目标函数为

$$f(x) = \sum_{i=1}^{n} \left[(1 - x_{2i-1})^2 + 10(x_{2i} - x_{2i-1}^2)^2 \right].$$

它可以看成经典 Rosenbrock 函数在高维下的成组扩展。每一对变量 (x_{2i-1}, x_{2i}) 都形成一个弯曲的谷底结构，因此这个问题常被用来测试优化算法在病态情形下的表现。

该问题的最优解为

$$x^* = (1, 1, \ldots, 1)^T,$$

对应最优函数值 $f(x^*) = 0$。

1.2 梯度、Hessian 及其结构

记

$$\phi_i(a, b) = (1 - a)^2 + 10(b - a^2)^2,$$

则第 i 对变量对应的梯度为

$$\nabla \phi_i(a, b) = \begin{pmatrix} -40a(b - a^2) - 2(1 - a) \\ 20(b - a^2) \end{pmatrix}.$$

对应的 Hessian 小块为

$$\nabla^2 \phi_i(a, b) = \begin{pmatrix} 120a^2 - 40b + 2 & -40a \\ -40a & 20 \end{pmatrix}.$$

于是扩展 Rosenbrock 的整体 Hessian 具有按 2×2 小块排列的结构。它不是任意稠密矩阵；但如果程序里直接用一个 $2n \times 2n$ 的 NumPy 二维数组去构造完整 Hessian，在大规模时会带来很大的内存与时间开销。

以 $n = 30000$ 为例，变量维数是 $2n = 60000$。若按稠密矩阵形式显式存储一个 60000×60000 的 Hessian，其双精度内存需求约为

$$60000^2 \times 8 \text{ Byte} \approx 28.8 \text{ GB},$$

这在普通实验环境中已经非常不现实。

1.3 为什么选 FR 做对比

为了体现不同算法思想在大规模问题上的差异，我在主实验中选取了两类方法做比较：

- `FR + Armijo`：代表一阶非线性共轭梯度法；

- `Newton-CG + Armijo`：代表利用二阶信息的非精确牛顿法。

之所以这样选，是因为这两类方法都比较经典，而且各自代表性很强。FR 方法只用梯度信息，单步开销相对较低；Newton-CG 则试图利用局部曲率信息，但又避免直接求解完整牛顿方程。把这两种方法放在一起比较，能比较清楚地比较**大规模一阶方法**和**大规模二阶方法**的差别。

1.4 FR 共轭梯度法简述

非线性共轭梯度法的基本思路，是在每一轮用当前梯度和上一轮方向共同构造新的搜索方向：

$$d_0 = -g_0, \qquad d_k = -g_k + \beta_k d_{k-1}.$$

其中 Fletcher–Reeves 公式取

$$\beta_k^{FR} = \frac{g_k^T g_k}{g_{k-1}^T g_{k-1}}.$$

这种方法的直观理解是：它比最速下降法多记住了一点上一步的信息，因此通常不会像最速下降法那样频繁地来回摆动。不过它本质上仍然属于一阶方法，对曲率的利用有限，所以在病态问题上迭代次数可能会比较多。

1.5 非精确牛顿法与内层共轭梯度

标准牛顿法需要求解

$$\nabla^2 f(x_k) d_k = -\nabla f(x_k),$$

然后再用 d_k 作为搜索方向。问题在于，大规模情况下既不适合显式构造完整 Hessian，也不适合每轮都精确求解这个线性方程组。

非精确牛顿法的思路是：**方向仍然按牛顿思想求，但不要求每轮都精确解到非常高的精度**。在本次实验中，我采用内层共轭梯度法来近似求解牛顿方程，也就是常说的 Newton-CG。

算法可以理解成两层循环：

- 外层：计算梯度，判断终止条件，做线搜索并更新迭代点；
- 内层：用共轭梯度法近似求解当前点的牛顿方向。

在第 k 次外迭代中，记

$$g_k = \nabla f(x_k), \qquad A_k = \nabla^2 f(x_k),$$

内层 CG 从

$$r_0 = g_k, \qquad p_0 = -r_0, \qquad d_0 = 0$$

开始迭代，并按

$$\alpha_j = \frac{r_j^T r_j}{p_j^T A_k p_j}, \qquad d_{j+1} = d_j + \alpha_j p_j, \qquad r_{j+1} = r_j + \alpha_j A_k p_j$$

更新。

若出现负曲率，即

$$p_j^T A_k p_j \le 0,$$

则说明当前局部曲率不再适合继续按标准 CG 方式推进，此时算法退回到已得到的可用方向。若残差满足容差条件，则提前结束内层迭代。

外层更新使用 Armijo 回溯线搜索：

$$x_{k+1} = x_k + \alpha_k d_k.$$

1.6 为什么要 Hessian-向量积

对于本题中的每一对变量，若向量 v 的对应小块写为

$$v_i = \begin{pmatrix} v_{2i-1} \\ v_{2i} \end{pmatrix},$$

则有

$$\nabla^2 \phi_i(a,b)\, v_i = \begin{pmatrix} (120a^2 - 40b + 2)v_{2i-1} - 40a\, v_{2i} \\ -40a\, v_{2i-1} + 20 v_{2i} \end{pmatrix}.$$

这说明如果算法只需要 $H(x)v$，那么并不一定要先把完整 Hessian 建出来。只要按分块公式直接算乘积就可以了。

在我的实现里，优化版目标函数提供了 `hess_vec` 接口。这样 `conjugate_gradient_inexact_newton` 在内层 CG 中就可以直接调用 Hessian-向量积，从而把内存和运算都压到更合理的水平。

2 程序实现说明

2.1 实验流程

`work4.py` 的流程比较直接，就是先做“程序优化前后对比”，再做“FR 与 Newton-CG 的算法比较”。前一部分固定算法，只改变目标函数实现方式，用来观察向量化和 Hessian-向量积对运行时间的影响；后一部分固定为优化后的目标函数实现，再比较一阶方法和二阶方法的效果。

程序统一记录运行时间、迭代次数、最终函数值、是否收敛和梯度范数，并把结果保存成表格，同时画出运行时间曲线和收敛曲线。

2.2 实现要点

在 `optimization/problems.py` 的 `extended_rosenbrock_objective` 中，我保留了两种版本：

- `optimized=False`：使用 Python 层 `for` 循环，并显式构造 Hessian；

- `optimized=True`：使用 NumPy 切片向量化，并提供 `hess_vec`。

前者更接近“直接把数学公式逐项翻译成代码”的写法，便于理解；后者则更接近真正适合大规模数值实验的写法。

2.3 实验参数

本次实验采用如下参数设置：

- 初始点统一取重复的 $(-1.2, 1.0)$；
- 外层终止阈值为 $\|\nabla f(x_k)\| < 10^{-5}$；
- 最大外层迭代次数设为 200；
- Newton-CG 的最大内层迭代次数设为 100；
- 线搜索统一采用 Armijo 回溯线搜索。

这样设置的原因比较直接：一方面它和课上常见实验设置一致，便于比较；另一方面这些参数已经足够让算法在本题上稳定收敛，不需要再做太复杂的调参。

具体代码主要集中在 `optimization/problems.py`、`work4/work4.py` 和 `optimization/optimizers/` 中。这里不再大段展示源码，只结合实验结果讨论实现思路和效果。

3 实验结果与分析

3.1 程序优化前后时间对比

为了只观察实现优化的影响，我先固定算法为 Newton-CG，然后比较扩展 Rosenbrock 在朴素实现和优化实现下的运行时间。结果如表 1 所示。

表 1: Newton-CG 在程序优化前后的运行时间对比

n	维数 $2n$	实现方式	运行时间/s	迭代次数	加速比
100	200	优化前	0.02738	19	2.90
100	200	优化后	0.00944	19	2.90
300	600	优化前	0.10302	18	18.40
300	600	优化后	0.00560	18	18.40
500	1000	优化前	0.91814	18	42.53
500	1000	优化后	0.02159	18	42.53

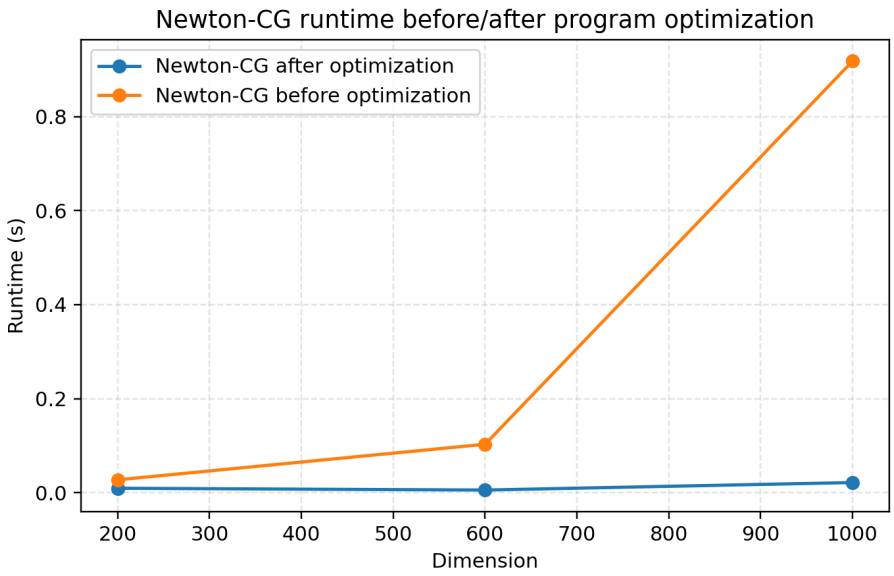

图 1: Newton-CG 在程序优化前后的运行时间曲线

从表 1 可以先看到一个非常明确的现象：**优化前后迭代次数完全相同，但运行时间差异很大**。这说明本次程序优化并没有改变算法路径，也没有改变收敛结果，它提升的纯粹是每一步计算的执行效率。

进一步看加速比：

- 当 $n = 100$ 时，加速比约为 2.90；
- 当 $n = 300$ 时，加速比约为 18.40；
- 当 $n = 500$ 时，加速比约为 42.53。

随着规模增大，加速效果越来越明显。向量化实现和 Hessian-向量积更多利用了 NumPy 的底层批量计算能力，因此规模越大越占优势。

3.2 FR 与 Newton-CG 的比较

在完成程序优化后，我再用优化版目标函数对 FR 和 Newton-CG 做主实验比较。结果如表 2 所示。

表 2: FR 与 Newton-CG 在扩展 Rosenbrock 上的比较结果

n	方法	运行时间/s	迭代次数	f^*	是否收敛	$\|\nabla f(x^*)\|$
1000	FR + Armijo	0.04522	55	4.70×10^{-11}	是	6.32×10^{-6}
1000	Newton-CG + Armijo	0.02697	19	2.12×10^{-17}	是	6.09×10^{-8}
10000	FR + Armijo	3.49834	158	1.16×10^{-10}	是	9.58×10^{-6}
10000	Newton-CG + Armijo	0.08689	19	2.12×10^{-16}	是	1.93×10^{-7}
30000	FR + Armijo	3.87942	184	6.63×10^{-12}	是	2.78×10^{-6}
30000	Newton-CG + Armijo	0.27949	19	6.36×10^{-16}	是	3.34×10^{-7}

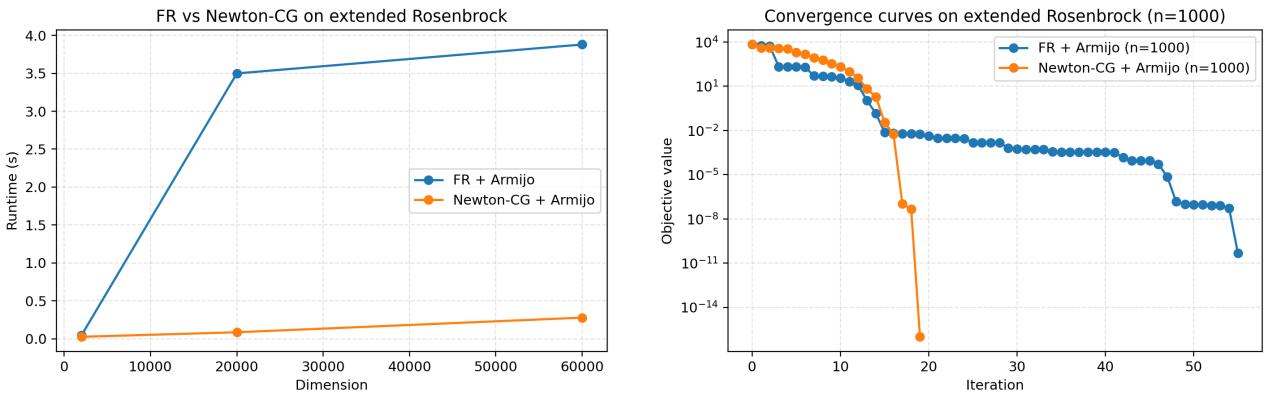

(a) 运行时间比较 (b) 收敛曲线（$n = 1000$）

图 2: FR 与 Newton-CG 的效率与收敛过程比较

从表 2 可以得到几个比较清楚的结论。

1. 两种方法都能收敛，但 Newton-CG 收敛更快

在三个规模下，两种算法都达到了收敛要求。FR 作为一阶方法，虽然速度不一定快，但在这个问题上仍然是有效的。

不过从外层迭代次数看，Newton-CG 始终稳定在 19 次左右，而 FR 分别需要 55、158、184 次。可以看出 Newton-CG 对曲率的利用更充分，能更快找到合适的下降方向。

2. Newton-CG 的时间优势在大规模下更明显

把 FR 与 Newton-CG 的运行时间相除，可得到大致的时间加速比：

- $n = 1000$ 时约为 1.68；
- $n = 10000$ 时约为 40.26；
- $n = 30000$ 时约为 13.88。

也就是说，在中大规模下，Newton-CG 比 FR 快了接近一个数量级。

3. Newton-CG 最终精度也更高

从最终函数值和梯度范数看，Newton-CG 的结果普遍更好。例如：

- 在 $n = 10000$ 时，FR 的最终梯度范数约为 9.58×10^{-6}，已经接近停止阈值；
- 同样规模下，Newton-CG 的最终梯度范数约为 1.93×10^{-7}，明显更小。

这说明二阶信息不仅减少了迭代次数，也让算法更容易进入高精度区域。

4. 收敛曲线更能直观看出差异

从图 2 中 $n = 1000$ 的收敛曲线可以看到，Newton-CG 的目标函数值下降得更陡，前十几步内就快速逼近最优值；而 FR 的下降过程相对更慢。